TECHNISCHE MODELVERGELIJKING

AI-modellen voor OpenCode

Benchmark · kosteneffectiviteit · EU-dataresidentie · privacy

$1,59
90M-tokenmix: DeepSeek V4.1 Flash via Go, off-peak (usage-equivalent)

$4 / 1.000
Mistral OCR 4.1: paginaprijs voor gespecialiseerde document-OCR

EU ≠ ZDR
Verwerkingsregio, retentie en modeltraining zijn aparte controles

Peildatum: 13 oktober 2026 · Prijzen in USD, tenzij anders vermeld · Scores zijn kwalitatieve inschattingen, geen gecontroleerde benchmarkrun

Managementsamenvatting

- **Beste algemene kwaliteit:** Claude Sonnet 5.5 en GPT-6.1 Sol voor code, VBA, Office-bestanden en technisch-juridische documentanalyse. GPT-6 Astra en Claude Opus 5.5 zijn premiumopties voor uitzonderlijk moeilijke taken.
- **Beste lage tokenkosten:** DeepSeek V4.1 Flash via Go buiten piekuren (~$1,59 per opgegeven sessiemix), GPT-6 Luna en Claude Haiku 5.5 (~$1,78). Go is een abonnement met modelquota; deze bedragen zijn verbruikswaarden, geen extra factuur per sessie.
- **Beste specialist voor scans:** Mistral OCR 4.1 voor gedrukte PDF's, tabellen en layout. Gebruik een vision-model voor werffoto's en controleer handschrift/serienummers menselijk.
- **Beste EU-hostingkeuze:** Scaleway Serverless of OVHcloud AI Endpoints. Mistral en OpenAI kunnen ook EU-inference aanbieden, maar daarvoor moet de regionale route expliciet worden gekozen.

> **Interpretatie van de benchmark:** 6,5M unieke input + 82,7M cache-hit input + 0,61M output = **89,81M** tokens. De 90M is dus afgerond; de ontbrekende 0,19M tokens zijn niet geprijsd. De berekening veronderstelt echte cachehits en sluit cachevulling, toolkosten, belastingen en eventuele extra reasoning-output uit.

1. Actuele modellen en routes

OpenCode V2 gebruikt **OpenCode Console** voor pay-as-you-go en **OpenCode Go / Go Plus** als abonnement ($10/$40 per maand). De actuele catalogi zijn provider- en accountafhankelijk. Go bevat onder meer GPT-6 Luna, Claude Haiku 5.5, DeepSeek V4.1 Flash/V4 Pro en Qwen3.8 Flash. Console bevat onder meer GPT-6 Astra/6.1 Sol/Luna, Claude Sonnet/Opus 5.5 en Mistral Large 4. BYOK en OpenAI-compatible custom endpoints zijn eveneens mogelijk.

Referentie uit de vraag	Status op peildatum	Actuele positionering
DeepSeek V3 / Coder	Niet in de geraadpleegde actuele OpenCode-catalogus	Vergelijk met DeepSeek V4.1 Flash (budget) en V4 Pro (zwaardere code-/agenttaken).
Claude Sonnet 5 / Haiku 3.5	Sonnet 5.5 is actueel; Haiku 3.5 is legacy/uitgefaseerd	Sonnet 5.5 voor moeilijke taken; Haiku 5.5 voor goedkope, snelle assistentie.
GPT-4o / 4o-mini	Beschikbaar als direct-API-referentie, maar niet meer de eerste keuze	GPT-6 Luna voor goedkoop werk; GPT-6.1 Sol voor zwaardere analyse.
Qwen3-Coder-30B	Scaleway Serverless EOL sinds 1 oktober 2026	Gebruik de actieve Qwen3.8-27B of Qwen3.6-35B-A3B-route.
Nieuwe relevante modellen	Actueel	Claude Sonnet 5.5, GPT-6.1 Sol/Astra, Mistral Large 4, Qwen3.8 en DeepSeek V4.1.

OpenCode “Zen” wordt in de huidige V2-documentatie aangeduid als Console. Custom providers kunnen via OpenCode V2 worden ingesteld; tarieven en privacy volgen de gekozen provider en endpoint.

2. Vergelijkende matrix — functionaliteitsscores

Schaal: 1 = niet geschikt, 5 = bruikbaar met controle, 8 = sterk, 10 = zeer sterk/gespecialiseerd. PDF- en Office-scores gaan over de kwaliteit van modeloutput en scripts; de agent en lokale tools moeten de bestanden nog daadwerkelijk maken en valideren.

Model / route	PDF opbouwen	Scans / OCR	XLSX / DOCX	VBA	Code / FIM	Bestek NL/FR	Assistent
GPT-6 Astra · Console	10	9,5	9,5	9,5	10	10	9,5
GPT-6.1 Sol · Console/BYOK	9,5	9	9,5	9,5	9,5	9,5	9
GPT-6 Luna · Go/Console	8	8	8	8	8,5	8	8,5
Claude Opus 5.5 · Console	10	9,5	10	9,5	10	10	9,5
Claude Sonnet 5.5 · Console/API	9,5	9	9,5	9,5	9,5	9,5	9
Claude Haiku 5.5 · Go/Console	7,5	8	8	7,5	7,5	8	8,5
Mistral Large 4 · Console/API	8,5	9	8,5	8	8,5	9	8,5
DeepSeek V4 Pro · Go	8,5	6,5	8,5	8,5	9	8,5	8,5
DeepSeek V4.1 Flash · Go	7,5	6	7,5	7	8	7,8	7,6
DeepSeek V4 Flash Vision Exp · Go	7,5	8,5	7,5	7	8	7,5	7,5
Qwen3.8 Max · Console	8,5	7	8,5	8	8,5	8,5	8,5
Qwen3.8 Flash · Go/Console	7,5	6	7,5	7	8	7,5	7,8
Qwen3.8-27B · Scaleway	8	8,5	8	7,5	8,5	8	8
Codestral 25.08 · Mistral API	8,5	2	8	8	9,5 FIM	6,5	6,5
Mistral Small 4 · Mistral API	8	6	8	7,5	8	7,5	7,8
Ministral 3 14B · Mistral API	7,5	6,5	7,5	7	7,5	7	7,5
OVH Qwen3.5-9B	7	7,5	7	6,5	7	7,5	7,5
GPT-4o · direct API	8	8,5	8	7,5	8	8	8,3
GPT-4o mini · direct API	7	7,5	7	6,5	7	7	7,6
Claude Haiku 3.5 · legacy	6,5	7	6,5	6	6,5	7	7,5

> **OCR-specialist:** Mistral OCR 4.1 scoort naar schatting 9,5/10 voor gedrukte PDF’s, tabellen en structuur; circa 7–8/10 voor handschrift. Codestral is juist sterk in FIM-codeaanvulling, niet in visuele OCR. Voor volledige PDF- of Office-bestanden blijven lokale scripts, rendering en menselijke controle essentieel.

Scores zijn kwalitatieve inschattingen op basis van publieke modelmogelijkheden en providerdocumentatie; geen model is met identieke JACOPS-prompts blind getest. De OCR-scores voor OpenCode-routes zijn conservatief waar de exacte image-input-capability van de route niet expliciet is vastgelegd.

3. Privacy en EU-dataresidentie

Privacy hoort bij de combinatie van model, provider, endpoint, accountinstellingen en contract. De onderstaande drie cijfers scheiden EU-verwerking, retentie/ZDR en training uit elkaar.

Route/configuratie	EU-inference	ZDR/retentie	Geen training	Kernvoorwaarde
Go: GPT-6 Luna / Haiku 5.5	3	4	10	Geen EU-pin; OpenCode vermeldt maximaal 30 dagen retentie voor deze API-routes.
Go: DeepSeek/Qwen/GLM e.a.	3	9–10	10	Go-documentatie vermeldt voor veel routes 0 dagen; DeepSeek-afspraak loopt t/m 31 okt. 2026.
Console: OpenAI/Anthropic-routes	6	4	10	Modellen worden in VS en EU gehost, maar de gebruiker krijgt geen expliciete request-level EU-pin in Console.
Console: Mistral-route	6	6	9–10	Training en retentie volgen Mistral-beleid; Console is niet hetzelfde als expliciet `api.eu.mistral.ai`.
OpenAI BYOK: EU-endpoint + goedgekeurde controls	10	10	10	GPT-6 Luna en GPT-6.1 Sol ondersteunen EU-verwerking; ZDR/MAM vereist goedkeuring.
Anthropic API BYOK: Sonnet 5.5	3	9	10	De eerste-partij API is standaard globaal; ZDR is een afzonderlijke, feature-afhankelijke regeling.
Mistral API: EU-endpoint + ZDR + opt-out	10	10	10	Regionale inference kost 10% extra; ZDR moet zijn goedgekeurd en geldt voor ondersteunde stateless API's.
Scaleway Serverless: Qwen3.8-27B	10	9	10	Inference in Parijs; standaard ZDR, met beperkte uitzonderingen voor incident-/foutonderzoek.
OVHcloud AI Endpoints: Qwen3.5-9B	10	10	10	OVHcloud zegt dat de dienst in de EU draait, geen training toepast en alleen billing-data bewaart.
Nebius publieke endpoint	3	4	10	Regio "Global"; ZDR moet aangezet worden. Zonder ZDR kan content voor speculative decoding worden bewaard.
Nebius dedicated EU + ZDR	10	10	10	EU-regio contractueel vastgelegd; ZDR schakelt speculative decoding uit.

Een EU-score is geen juridisch AVG-certificaat. Controleer DPA, subprocessors, transferbasis en eventuele bewaartermijnen. No-training, ZDR en regionale inference zijn verschillende toezeggingen.

4. Tarieven en caching — USD

Alle tokenprijzen zijn per miljoen tokens. “Cache read” betekent een echte cachehit. OpenCode Go-tarieven zijn equivalentverbruik binnen de abonnementsquota; Console en BYOK zijn pay-as-you-go. Belastingen, cachevulling en bijkomende tools zijn niet inbegrepen. Prijsindex: 10 bij ≤$2; 9 bij $2–4; 8 bij $4–8; 7 bij $8–16; 6 bij $16–32; 5 bij $32–64; lagere scores bij hogere kosten.

Route/model	Uniek	Cache read	Output	89,81M-mix	Prijsindex
Go/Console · GPT-6 Luna	$0,10	$0,01	$0,50	**$1,78**	10
Go · Claude Haiku 5.5, request ≤100K	$0,10	$0,01	$0,50	**$1,78**	10
Go · Haiku 5.5, request >100K	$0,50	$0,05	$2,50	**$8,91**	7
Go · DeepSeek V4.1 Flash off-peak	$0,15	$0,003	$0,60	**$1,59**	10
Go · DeepSeek V4.1 Flash peak	$0,30	$0,006	$1,20	**$3,18**	9
Go · DeepSeek V4 Pro off-peak	$0,66	$0,022	$1,98	**$7,32**	8
Go · DeepSeek V4 Pro peak	$1,32	$0,044	$3,96	**$14,63**	7
Go/Console · Qwen3.8 Flash	$0,15	$0,016	$0,47	**$2,58**	9
Console · GLM-5.3 Flash	$0,15	$0,03	$0,50	**$3,76**	9
Console · Qwen3.8 Max	$2,00	$0,25	$6,00	**$37,34**	5
Console · GPT-6.1 Sol	$2,00	$0,20	$10,00	**$35,64**	5
OpenAI BYOK · GPT-6.1 Sol	$2,00	$0,10	$10,00	**$27,37 global / $30,11 EU**	6
Console · GPT-6 Astra	$10,00	$1,00	$50,00	**$178,20**	1
Console · Claude Sonnet 5.5	$2,00	$0,20	$10,00	**$35,64**	5
Anthropic BYOK · Claude Sonnet 5.5	$2,00	$0,10	$10,00	**$27,37**	6
Console/API · Claude Opus 5.5	$4,00	$0,20	$20,00	**$54,74**	5
Console/API · Mistral Large 4, sale	$0,68	$0,07	$2,09	**$11,48 global / $12,63 EU**	7
Mistral API · Codestral 25.08	$0,30	$0,03	$0,90	**$4,98 global / $5,48 EU**	8
Mistral API · Small 4	$0,15	$0,015	$0,60	**$2,58 global / $2,84 EU**	9
Mistral API · Ministral 3 14B	$0,20	$0,02	$0,20	**$3,08 global / $3,38 EU**	9
Mistral API · Ministral 3 8B	$0,15	$0,015	$0,15	**$2,31 global / $2,54 EU**	9
OpenAI API · GPT-4o, referentie	$2,50	$1,25	$10,00	**$125,73**	3
OpenAI API · GPT-4o mini, referentie	$0,15	$0,075	$0,60	**$7,54**	8
Anthropic · Haiku 3.5, historisch	$0,80	$0,08	$4,00	**$14,26**	7

Prijsverschil per route: OpenCode Console rekent voor GPT-6.1 Sol en Claude Sonnet 5.5 $0,20/M cache-read; de upstream OpenAI- en Anthropic-API’s publiceren $0,10/M. In deze sessiemix scheelt direct BYOK daardoor $8,27 vóór eventuele EU-toeslag. EU-inference bij OpenAI/Mistral kan 10% kosten; Mistral Large 4 is momenteel geprijsd met een tijdelijke sale-rate.

EU-cloud en pagina-gebaseerde OCR

Provider/model	Input	Cache read	Output	Sessieschatting
Scaleway · DeepSeek V4.1 Flash	€0,60	€0,12	€1,80	**€14,92**
Scaleway · Qwen3.8-27B	€0,60	€0,12	€3,30	**€15,84**
OVHcloud · Qwen3.5-9B	€0,10	Niet vermeld	€0,15	**€9,01***
Mistral API · OCR 4.1	$4 / 1.000 pagina’s	$0,40 / 1.000 cachepagina’s	—	Per pagina, niet tokenmix

* OVH-berekening veronderstelt geen cachekorting: alle inputtokens worden aan het gepubliceerde standaardtarief gerekend. Scaleway heeft automatische caching; de benchmark neemt de gepubliceerde cache-readprijs aan. Scaleway biedt daarnaast een gratis eerste miljoen tokens en 50% batchkorting voor geschikte asynchrone workloads; die zijn niet in de tabel toegepast.

5. Performance-versus-kostenindex

De prijsindex in de tabellen kijkt alleen naar de tokenrekening. Onderstaande prijs-prestatiekeuzes wegen ook de taakgeschiktheid en absolute kwaliteit mee; het blijft een praktische inschatting.



Taak	Kwaliteitskeuze	Prijs-prestatiekeuze	Praktische aanpak
PDF opbouwen	Sonnet 5.5 / GPT-6.1 Sol	GPT-6 Luna voor standaardrapporten	Render lokaal met WeasyPrint/ReportLab en controleer fonts, tabellen en pagina-afbreking.
Scans/tabellen	Mistral OCR 4.1	OCR 4.1 op paginaprijs; Qwen3.8-27B voor visuele interpretatie	OCR-resultaat daarna laten structureren; twijfelwaarden en handschrift markeren.
XLSX/DOCX	Sonnet 5.5 / GPT-6.1 Sol	GPT-6 Luna voor eenvoudige templates	Laat de agent lokaal schrijven met `openpyxl`/`python-docx`; open en valideer de bestanden.
VBA	Sonnet 5.5 / GPT-6.1 Sol	DeepSeek V4 Pro via Go voor omvangrijke codeanalyse	Werk op een kopie van de workbook en test met representatieve data.
Lastenboeken	Sonnet 5.5 / GPT-6.1 Sol	Mistral Large 4 voor EU/Franse vaktaal; DeepSeek V4 Pro bij geëxtraheerde tekst	Werk per eis/clausule, behoud paginaverwijzingen en vraag om expliciete onzekerheden.

6. Eindadvies en positionering

Gebruik in OpenCode	Aanbevolen route/model	Opmerking
Dagelijkse agent en korte scripts	`opencode-go/gpt-6-luna` of `opencode-go/deepseek-v4.1-flash`	Go-quota; DeepSeek-tarief varieert met piekuren.
Zware code, VBA en Office	`opencode/claude-sonnet-5-5` of `opencode/gpt-6.1-sol`	BYOK kan bij veel cachehits goedkoper zijn dan Console; EU-route voor OpenAI vereist goedkeuring.
FIM-codeaanvulling	Codestral 25.08 via Mistral API	Specialist voor snelle code completion/FIM; geen algemene OCR-assistent.
PDF-scans en tabellen	Mistral OCR 4.1 + taalmodel voor analyse	Controleer of het OCR-model op de gekozen EU-regio beschikbaar is.
EU-gevoelige documenten	Scaleway Serverless, OVHcloud AI Endpoints of Nebius dedicated EU + ZDR	Custom provider in OpenCode; leg DPA, regio, retentie en subprocessors vast.

> **Praktische keuze:** gebruik een goedkoop Go-model voor routinevragen, schaal voor lastige VBA/contractanalyse op naar Sonnet 5.5 of GPT-6.1 Sol, en behandel OCR als aparte stap. Als EU-hosting verplicht is, gebruik dan een expliciet EU-endpoint of EU-cloud in plaats van aan te nemen dat OpenCode Go/Console de request regionaal routeert.

Bronnen

- OpenCode Go — modellen, quota, prijzen en privacy
- OpenCode Console — modellen, pay-as-you-go-prijzen en privacy
- OpenCode V2 — providers en custom endpoints
- OpenAI API-prijzen · OpenAI-dataretentie en EU-regio · GPT-6.1 Sol-modelkaart
- Anthropic-prijzen · Anthropic API-retentie/ZDR · Claude Sonnet 5.5-modelkaart
- Mistral-prijzen · Mistral regionale inference · Mistral ZDR · OCR 4.1 · Codestral
- Scaleway-prijzen · Scaleway-modellen/EOL · Scaleway-privacy
- OVHcloud AI Endpoints · OVH Qwen3.5-9B-modelpagina
- Nebius Token Factory — juridische en privacygids

Scores en kosten zijn peildatumgebonden inschattingen. Providerprijzen, cachevoorwaarden, modelstatus en quota kunnen wijzigen; controleer ze vóór productiegebruik en facturatie. De 90M-berekening is een tokenmodel, geen echte factuur.